OCS-WAF:
un Web Application Firewall basado en anomalías con clasificadores One-Class SVM

Nico Epp Ralf Funk

Universidad Nacional de Asunción
Facultad Politécnica
Ingeniería en Informática

Defensa Técnica de Trabajo Final de Grado

San Lorenzo, Paraguay
13 de Noviembre 2017

Contenido

Contenido

Propiedades de las aplicaciones web

- Ubicuidad
- Acceso anónimo
- Código escrito por no expertos
- Vulnerabilidades presentes

Vulnerabilidades en aplicaciones web

[1] Acunetix Web Application Vulnerability Report 2016 *(Datos entre abril 2015 y marzo 2016)*

Vulnerabilidades en aplicaciones web

- Tipos de vulnerabilides incluidas[1]
  - Severidad alta: XSS, Inyección SQL, entre otros
  - Severidad media: CSRF, DoS, entre otros

[1] Acunetix Web Application Vulnerability Report 2016 *(Datos entre abril 2015 y marzo 2016)*

Vulnerabilidades en aplicaciones web

- Estrategia de mitigación del riesgo de ataques:
  - Uso de Web Application Firewall (WAF)

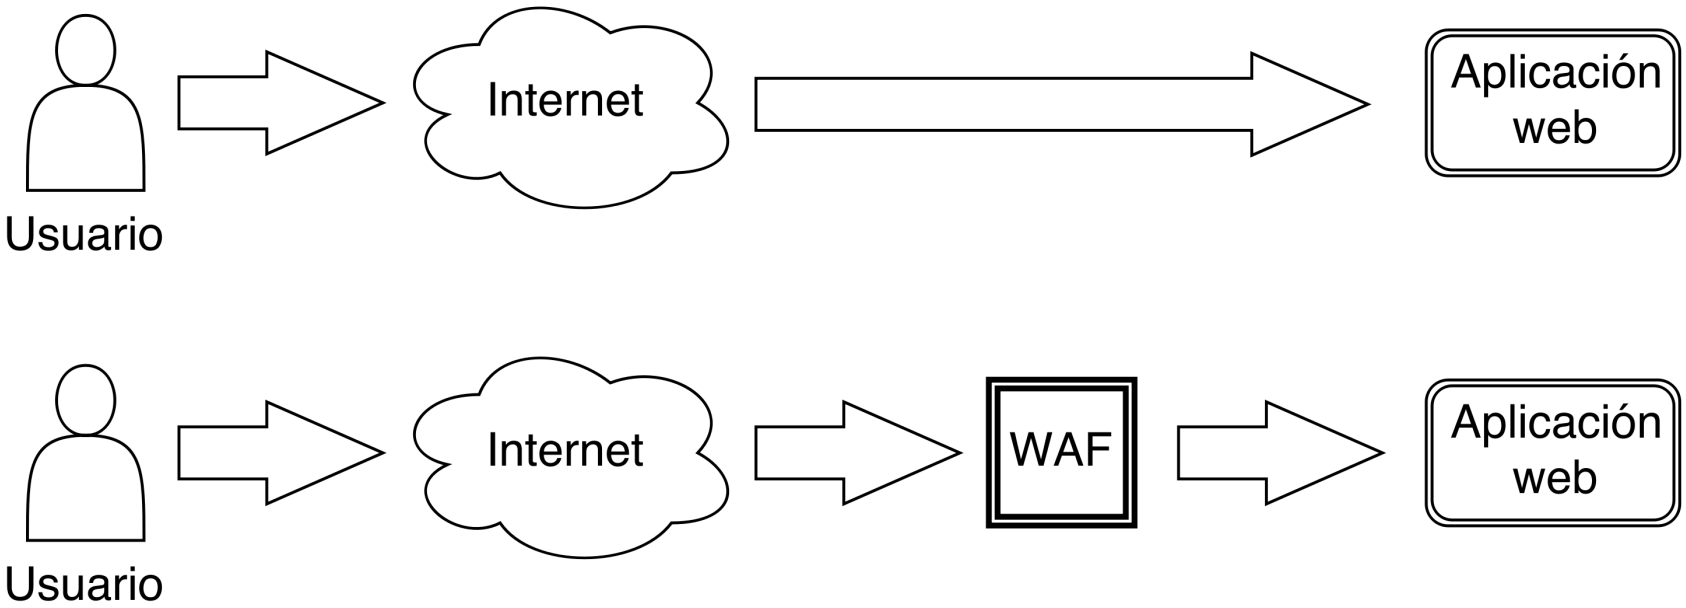

Sistemas de Deteción de Intrusiones (IDS)

Sistemas de Deteción de Intrusiones (IDS)

- Modo de respuesta:
  - Pasivo - detección (IDS)
  - Activo - prevención (IPS)

Sistemas de Deteción de Intrusiones (IDS)

- Modo de respuesta:
  - Pasivo - detección (IDS)
  - Activo - prevención (IPS)
- Fuente de datos:
  - *Host-based systems* (HIDS)
  - *Network-based systems* (NIDS)
    - Mensajes HTTP $\rightarrow$ WAF

Sistemas de Deteción de Intrusiones (IDS)

- Modo de respuesta:
  - Pasivo - detección (IDS)
  - Activo - prevención (IPS)
- Fuente de datos:
  - *Host-based systems* (HIDS)
  - *Network-based systems* (NIDS)
    - Mensajes HTTP $\rightarrow$ WAF
- Método de detección:
  - Por firmas de ataques
  - Por anomalías

WAF con deteción de anomalías

- Dos fases:
  - Fase de entrenamiento: construcción de modelos que describen mensajes HTTP normales
  - Fase de detección: comparación de nuevos mensajes con modelos construidos

WAF con deteción de anomalías

- Dos fases:
  - Fase de entrenamiento: construcción de modelos que describen mensajes HTTP normales
  - Fase de detección: comparación de nuevos mensajes con modelos construidos
- Ventaja: detección de ataques nuevos sin re-entrenar
- Desventaja: dificultad de contrucción de modelos significativos

WAF con deteción de anomalías

- Dos fases:
  - Fase de entrenamiento: construcción de modelos que describen mensajes HTTP normales
  - Fase de detección: comparación de nuevos mensajes con modelos construidos
- Ventaja: detección de ataques nuevos sin re-entrenar
- Desventaja: dificultad de contrucción de modelos significativos
- Estrategías de abordaje:
  - Métodos estadísticos (definición de *threshold*)
  - Problema de clasificación utilizando herramientas de *Machine Learning*

Problemas de clasificación y *Machine Learning*

Problemas de clasificación y *Machine Learning*

- Clasificación no supervisada

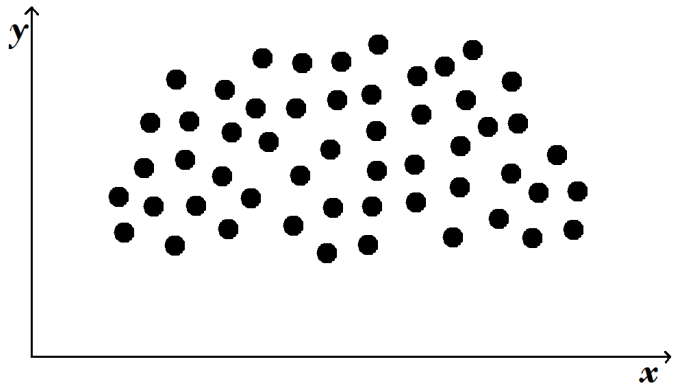

Problemas de clasificación y *Machine Learning*

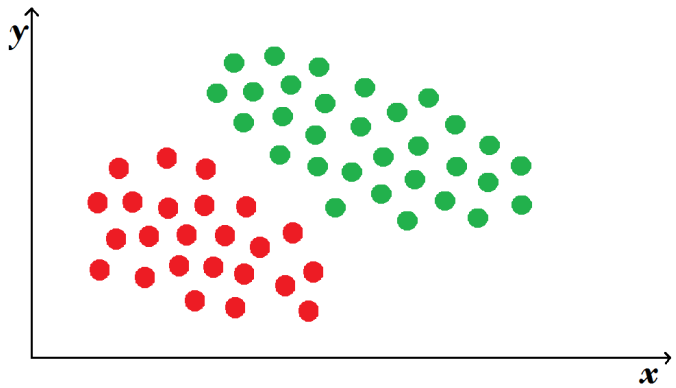

- Clasificación no supervisada
- Clasificación supervisada

Problemas de clasificación y *Machine Learning*

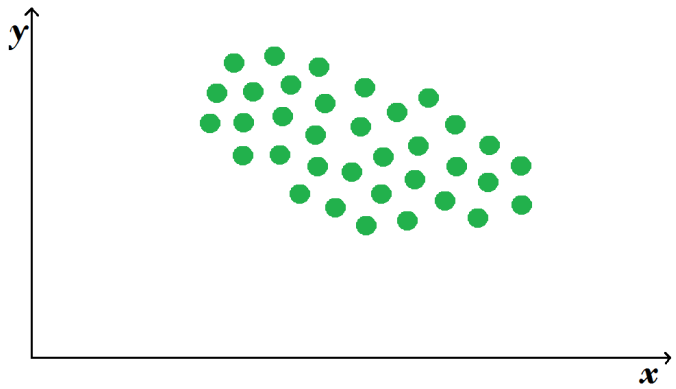

- Clasificación no supervisada
- Clasificación supervisada
- Clasificación semi-supervisada
  - Caso especial: entrenamiento con muestras de una sola clase OCC: *One-Class Classification*
  - Una herramienta posible: One-Class SVM

Objetivo general

Objetivo general

- Detectar mensajes HTTP anómalos entre las aplicaciones web y sus usuarios con el fin de mitigar los riesgos de ataques contra dichas aplicaciones, utilizando un WAF basado en clasificadores One-Class SVM.

Objetivos específicos

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.
2. Implementar un WAF basado en anomalías, utilizando los procesos de extracción de *features* diseñados junto con clasificadores One-Class SVM.

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.
2. Implementar un WAF basado en anomalías, utilizando los procesos de extracción de *features* diseñados junto con clasificadores One-Class SVM.
3. Evaluar la eficacia del WAF implementado en cuanto a la detección de mensajes HTTP anómalos.

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.
2. Implementar un WAF basado en anomalías, utilizando los procesos de extracción de *features* diseñados junto con clasificadores One-Class SVM.
3. Evaluar la eficacia del WAF implementado en cuanto a la detección de mensajes HTTP anómalos.
4. Analizar la viabilidad de utilizar el WAF implementado para detección de ataques en tiempo real.

Contenido

Detector de anomalías OCS-WAF

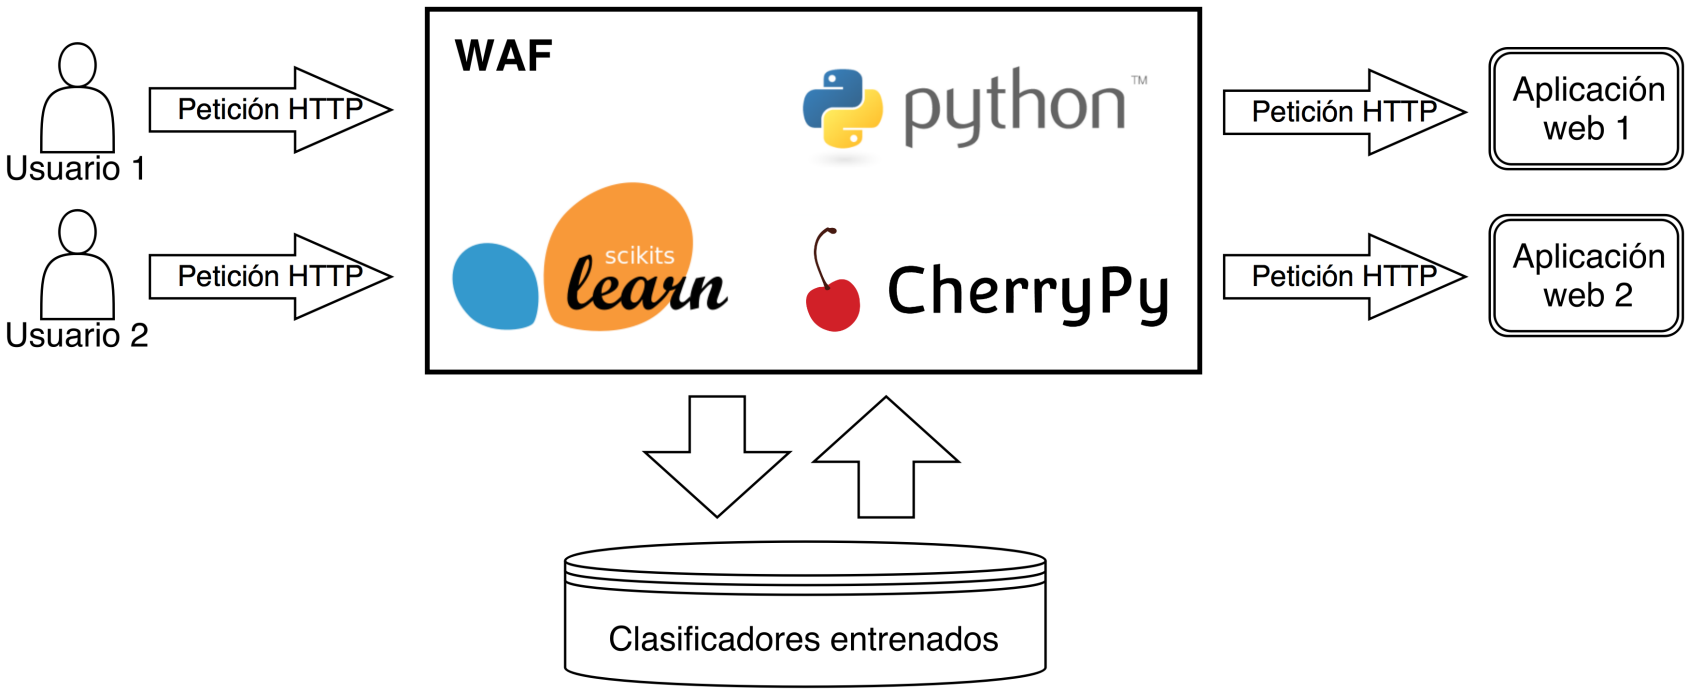

GitHub

https://github.com/nico-ralf-ii-fpuna/tfg

Fase de entrenamiento de OCS-WAF

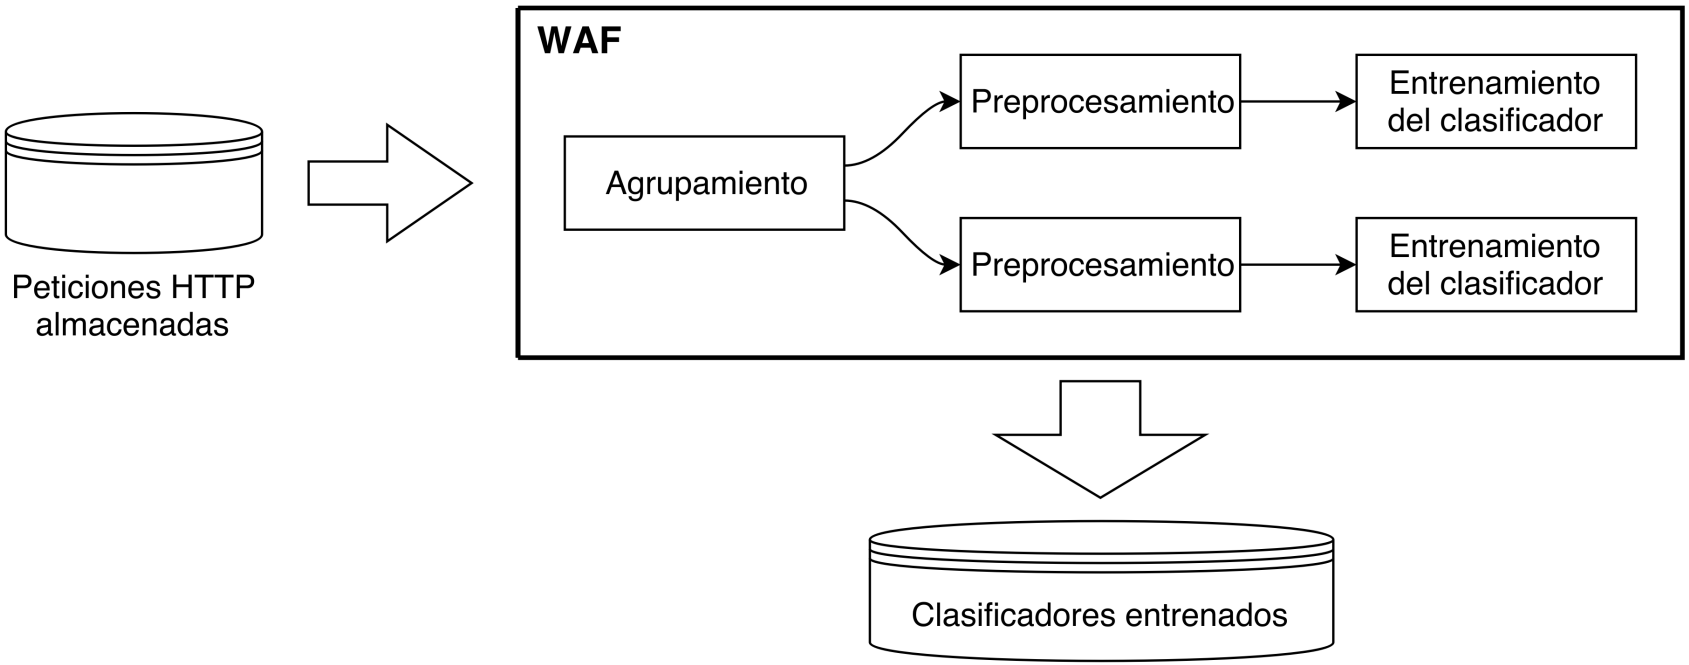

Estructura de peticiones HTTP

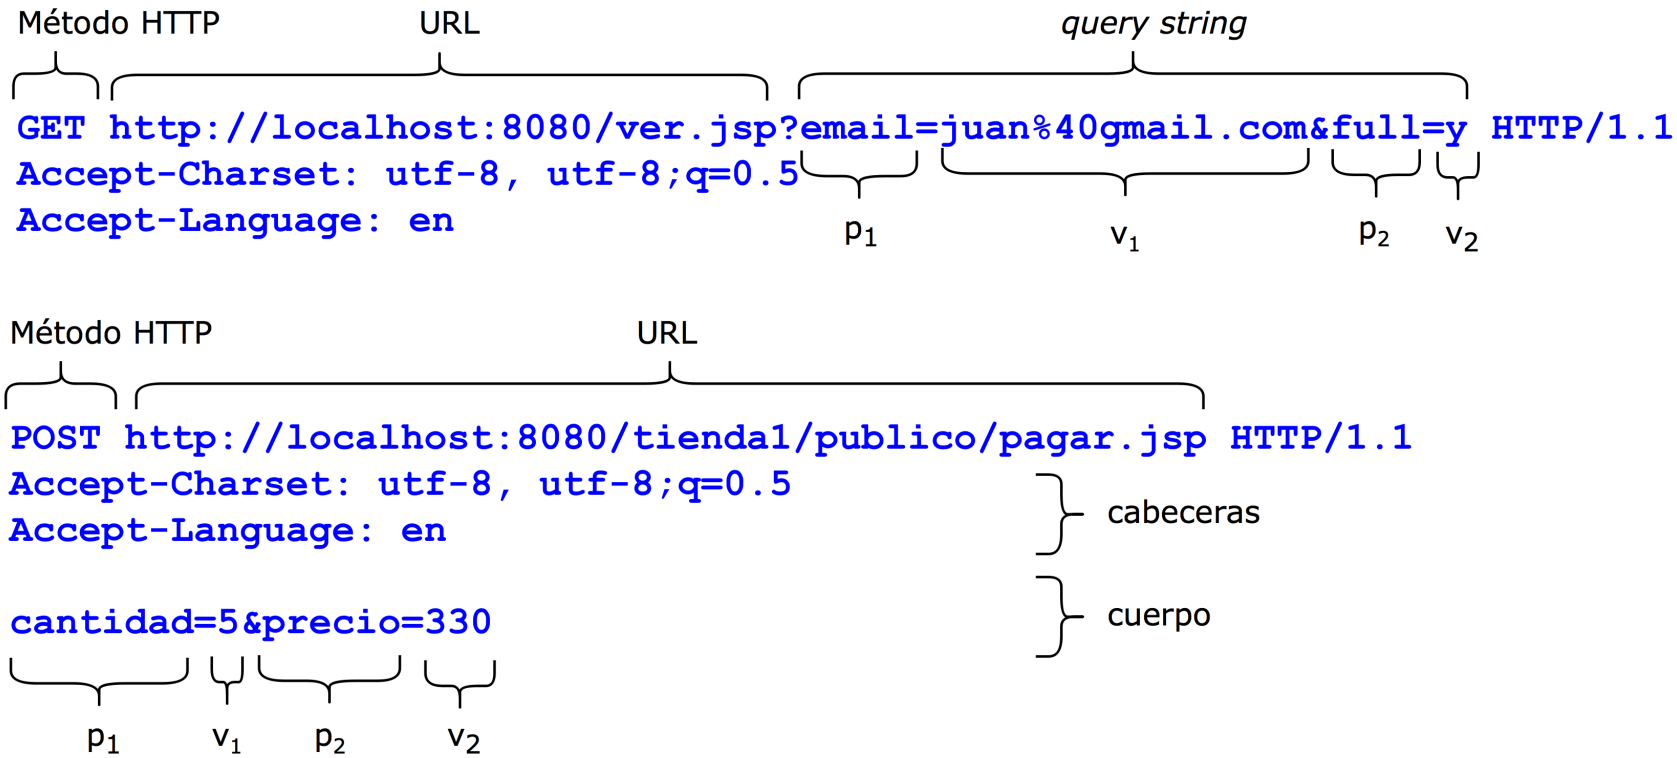

1. Paso de agrupamiento

1. Paso de agrupamiento

- Agrupación por método HTTP y URL

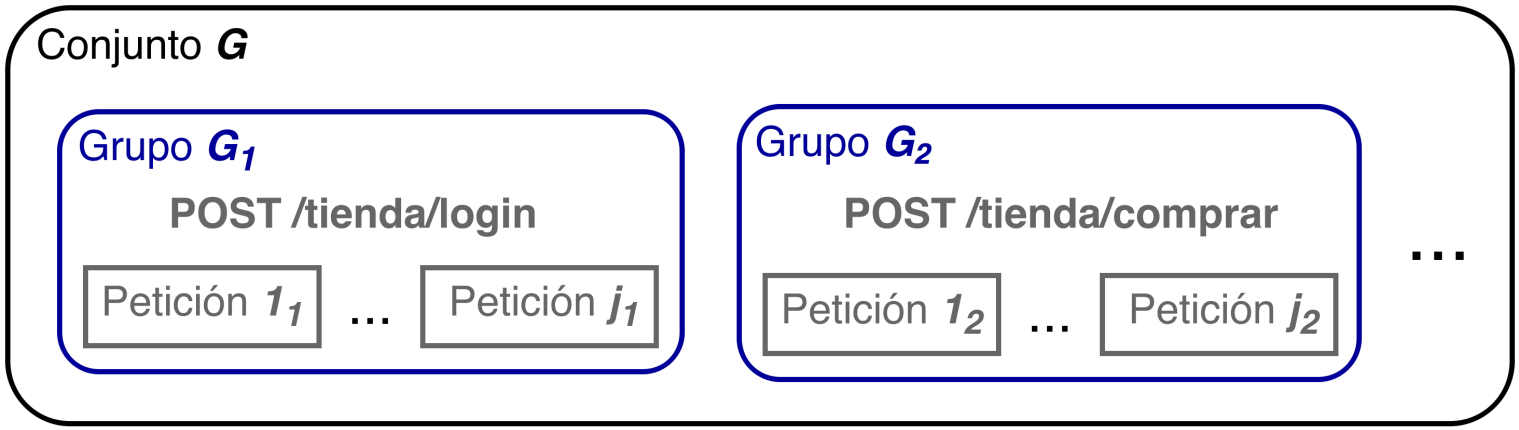

- Similitud entre peticiones de un mismo grupo G_i
  - $\forall i = 1, 2, \ldots, |G|$
- Descripciones más precisas del comportamiento normal dentro de cada grupo G_i

2. Paso de preprocesamiento

2. Paso de preprocesamiento

- Represetación de características de las peticiones mediante vectores numéricos de *features*
  - Petición HTTP $\rightarrow$ $\vec{f} \in \mathbb{R}^n$
  - dimensiones distintas para cada grupo G_i

2. Paso de preprocesamiento

- Represetación de características de las peticiones mediante vectores numéricos de *features*
  - Petición HTTP $\rightarrow$ $\vec{f} \in \mathbb{R}^n$
  - dimensiones distintas para cada grupo G_i
- Características analizadas por OCS-WAF:
  - Distribución de caracteres
  - Entropía
  - Cantidad de caracteres

2. Paso de preprocesamiento

- Distribución de caracteres
  - Aporte de Kruegel y Vigna[2]
  - Distribución de frecuencias relativas de caracteres
  - Suma de frecuencias relativas en cinco intervalos

[2] Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.

2. Paso de preprocesamiento

- Distribución de caracteres
  - Aporte de Kruegel y Vigna[2]
  - Distribución de frecuencias relativas de caracteres
  - Suma de frecuencias relativas en cinco intervalos

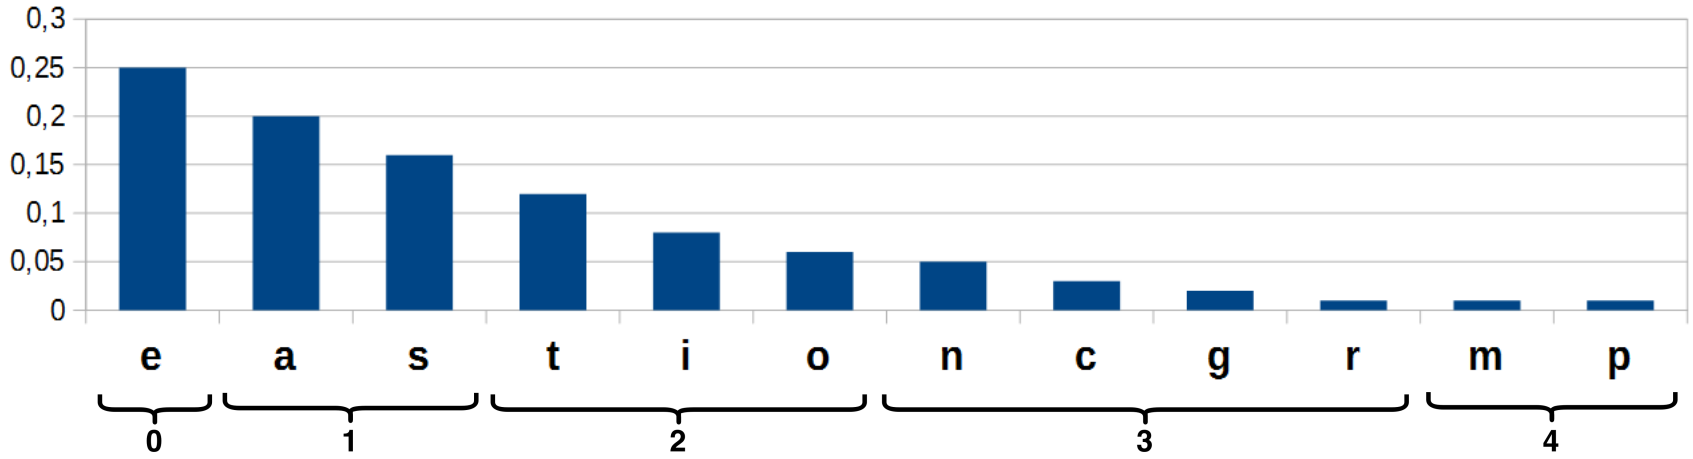

[2]Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.

2. Paso de preprocesamiento

- Distribución de caracteres
  - Aporte de Kruegel y Vigna[2]
  - Distribución de frecuencias relativas de caracteres
  - Suma de frecuencias relativas en cinco intervalos

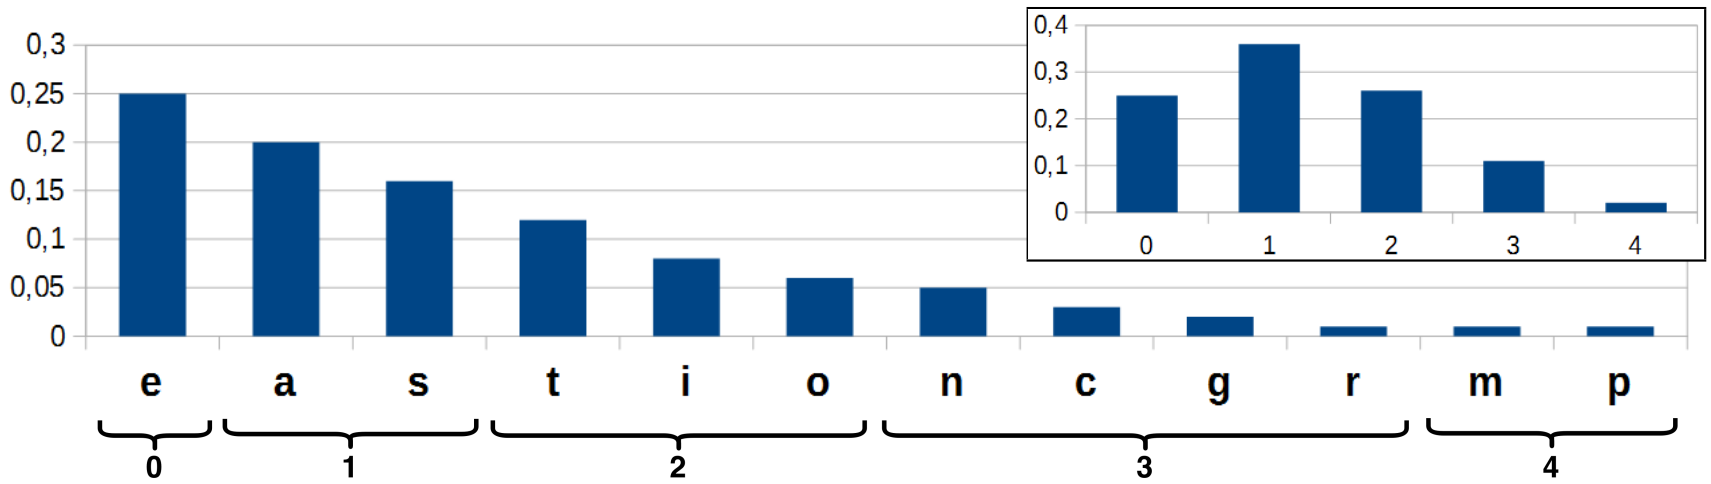

[2]Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.

2. Paso de preprocesamiento

- Distribución de caracteres
  - Aporte de Kruegel y Vigna[2]
  - Distribución de frecuencias relativas de caracteres
  - Suma de frecuencias relativas en cinco intervalos

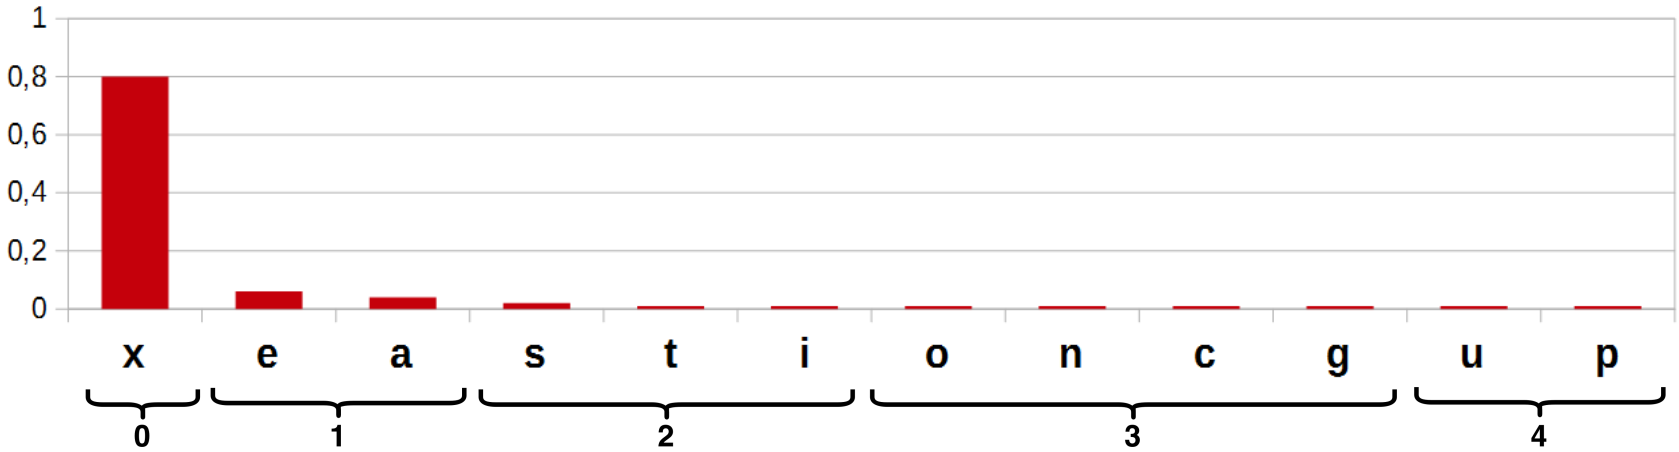

[2]Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.

2. Paso de preprocesamiento

- Distribución de caracteres
  - Aporte de Kruegel y Vigna[2]
  - Distribución de frecuencias relativas de caracteres
  - Suma de frecuencias relativas en cinco intervalos

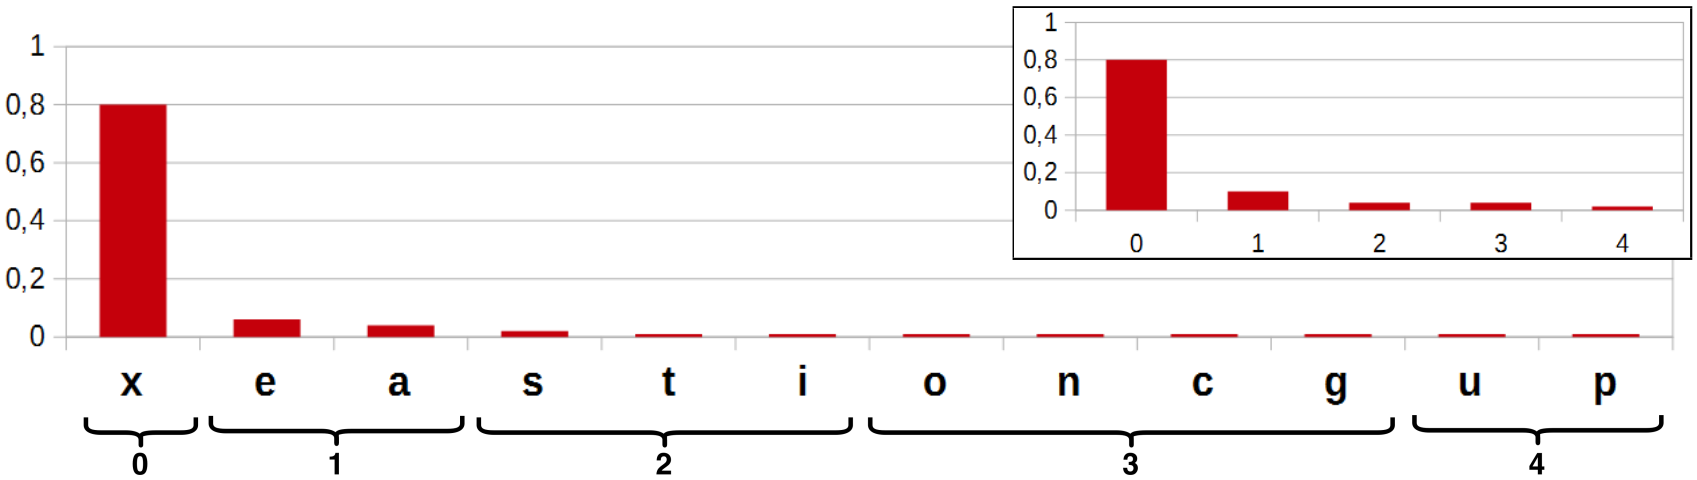

[2]Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.

2. Paso de preprocesamiento

- Entropía (Teoría de la información)
  - Relación entre longitud del valor y cantidad de caracteres distintos
  - Aporte de Nguyen et. al.[3]
  - Fórmula propuesta por Claude Shannon[4]

$$H(x) = -\sum_{i=1}^{|c|} \left(\frac{c_i}{|x|} \times \log_2 \frac{c_i}{|x|} \right)$$

Ejemplo

$x = \text{aabbc}$

$|x| = 5$

$|c| = 3$

$c_1 = 2 \quad \rightarrow \quad \text{a}$

$c_2 = 2 \quad \rightarrow \quad \text{b}$

$c_3 = 1 \quad \rightarrow \quad \text{c}$

[3] Nguyen et. al. (2011) *Application of the generic feature selection measure in detection of web attacks*.

[4] Shannon (1948) *A Mathematical Theory of Communication*.

2. Paso de preprocesamiento

- Entropía (Teoría de la información)
  - Relación entre longitud del valor y cantidad de caracteres distintos
  - Aporte de Nguyen et. al.[3]
  - Fórmula propuesta por Claude Shannon[4]

Ejemplo: petición normal

- $H(x) = 5{,}092$

Ejemplo: petición con *buffer overflow*

- $H(x) = 0.901$

[3] Nguyen et. al. (2011) *Application of the generic feature selection measure in detection of web attacks*.
[4] Shannon (1948) *A Mathematical Theory of Communication*.

2. Paso de preprocesamiento

- Cantidad de caracteres
  - Aporte de Kruegel y Vigna[5], y Nguyen et. al.[6]
  - Conjuntos de caracteres
    1. Todos
    2. Dígitos
    3. Letras
    4. Otros caracteres

[5] Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.
[6] Nguyen et. al. (2011) *Application of the generic feature selection measure in detection of web attacks*.

2. Paso de preprocesamiento

- Cantidad de caracteres
  - Aporte de Kruegel y Vigna[5], y Nguyen et. al.[6]
  - Conjuntos de caracteres
    1. Todos
    2. Dígitos
    3. Letras
    4. Otros caracteres

Ejemplo: petición normal

Todos	=	100
Dígitos	=	9
Letras	=	74
Otros	=	17

Ejemplo: petición con *code injection*

Todos	=	132
Dígitos	=	21
Letras	=	78
Otros	=	33

[5] Kruegel and Vigna (2003) *Anomaly detection of web-based attacks*.
[6] Nguyen et. al. (2011) *Application of the generic feature selection measure in detection of web attacks*.

2. Paso de preprocesamiento

- 10 *features* extraídos

Features	Tipo de dato	Rango de valores
Dist. de caract. - intervalo 0	núm. reales	$[0, 1]$
Dist. de caract. - intervalo 1	núm. reales	$[0, 1]$
Dist. de caract. - intervalo 2	núm. reales	$[0, 1]$
Dist. de caract. - intervalo 3	núm. reales	$[0, 1]$
Dist. de caract. - intervalo 4	núm. reales	$[0, 1]$
Entropía	núm. reales	$[0, \infty)$
Longitud o cantidad total	núm. enteros	$[0, \infty)$
Cantidad de dígitos	núm. enteros	$[0, \infty)$
Cantidad de letras	núm. enteros	$[0, \infty)$
Cantidad de otros caracteres	núm. enteros	$[0, \infty)$

2. Paso de preprocesamiento

- Análisis de valores de parámetros
  - Obtención de parámetros presentes en peticiones de G_i
    - Q_i = ["email" , "full"]
    - B_i = [ ]
  - Extracción de *features* de cada valor de los parámetros

```
GET http://localhost:8080/ver.jsp?email=juan%40gmail.com&full=y HTTP/1.1
GET http://localhost:8080/ver.jsp?email=pedro%40gmail.com HTTP/1.1
GET http://localhost:8080/ver.jsp?email=jose%40gmail.com HTTP/1.1
```

2. Paso de preprocesamiento

- Composición del vector de *features*
  - $n_i = 10 \times (1 + |Q_i| + |B_i|)$

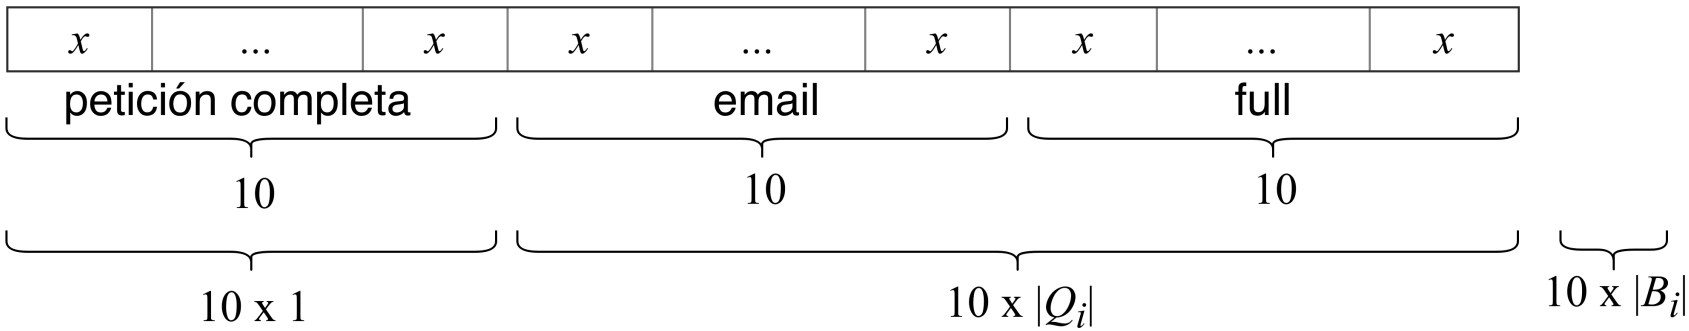


```
GET http://localhost:8080/ver.jsp?email=juan%40gmail.com&full=y HTTP/1.1
GET http://localhost:8080/ver.jsp?email=pedro%40gmail.com HTTP/1.1
GET http://localhost:8080/ver.jsp?email=jose%40gmail.com HTTP/1.1
```

2. Paso de preprocesamiento

- Composición del vector de *features*
  - $n_i = 10 \times (1 + |Q_i| + |B_i|)$

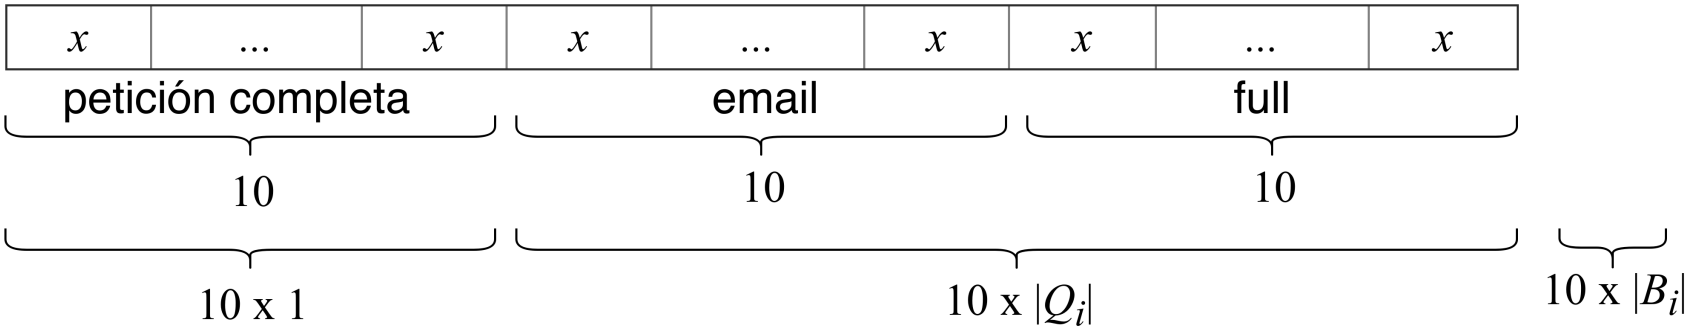

$$M_i = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,n_i} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,n_i} \\ \vdots & \vdots & \ddots & \vdots \\ x_{|G_i|,1} & x_{|G_i|,2} & \cdots & x_{|G_i|,n_i} \end{bmatrix}$$

2. Paso de preprocesamiento

- Escalamiento de *features* (normalización)

[7] Rieck (2009) Machine Learning for Application-Layer Intrusion Detection

2. Paso de preprocesamiento

- Escalamiento de *features* (normalización)
  - Problema:
    - Distintas importancias de *features* debido a rangos diferentes

[7] Rieck (2009) Machine Learning for Application-Layer Intrusion Detection

2. Paso de preprocesamiento

- Escalamiento de *features* (normalización)
  - Problema:
    - Distintas importancias de *features* debido a rangos diferentes
  - Finalidad del escalamiento estándar[7]:
    - Promedio cercano a 0 y una varianza cercana a 1 en cada *feature* (cada columna de M_i)

$$x_{\text{nuevo}} = \frac{x_{\text{actual}} - \mu_{\text{de la columna}}}{\sigma_{\text{de la columna}}}$$

[7] Rieck (2009) Machine Learning for Application-Layer Intrusion Detection

Support Vector Machine (SVM)

- Clasificadores binarios de aprendizaje supervisado
- Separación de clases mediante un hiperplano

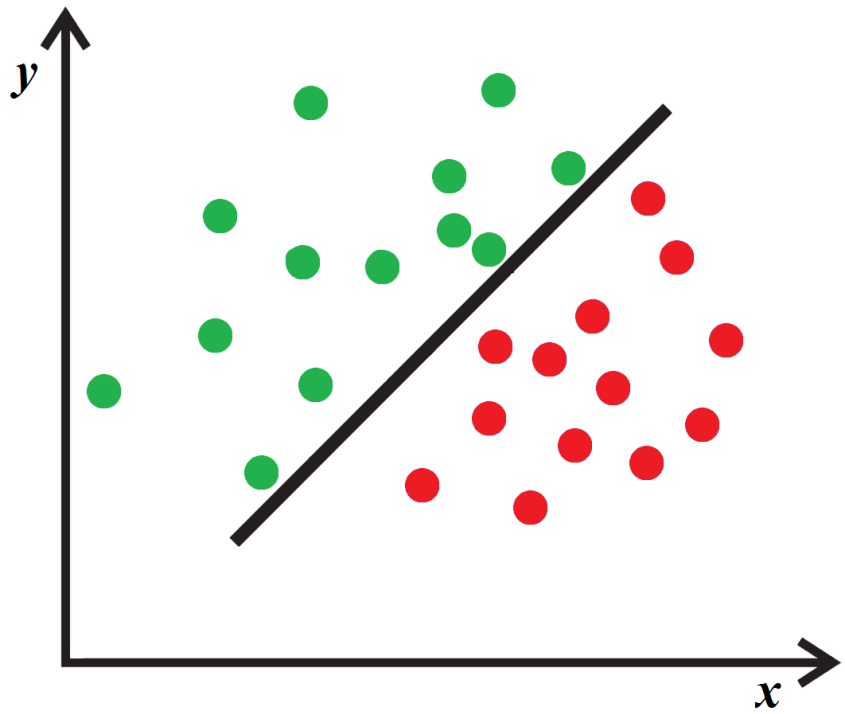

Support Vector Machine (SVM)

- Clasificadores binarios de aprendizaje supervisado
- Separación de clases mediante un hiperplano

One-Class SVM

- Versión modificada para problemas OCC
- Separación de única clase del origen

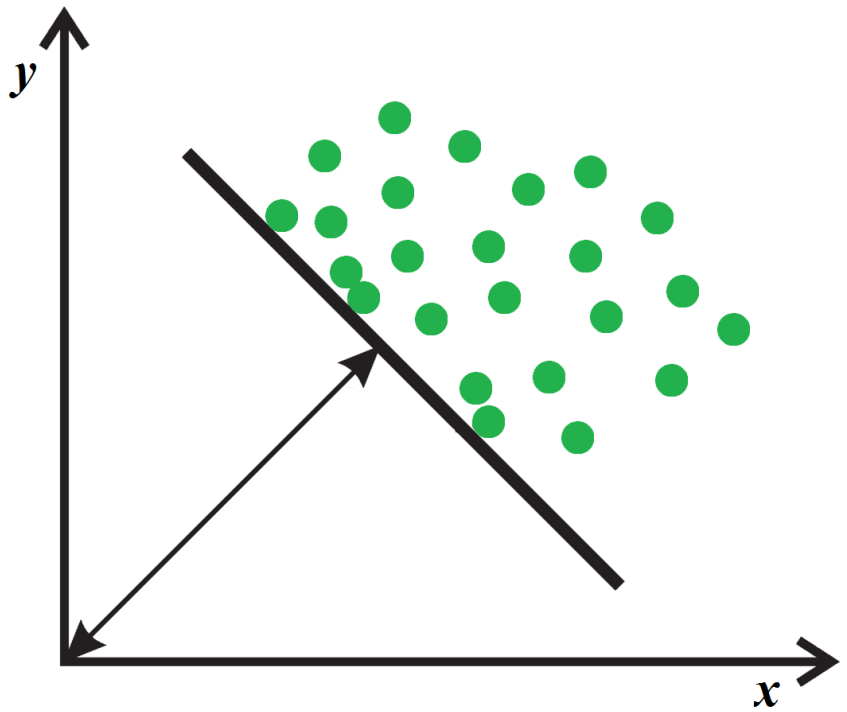

Support Vector Machine (SVM)

- Clasificadores binarios de aprendizaje supervisado
- Separación de clases mediante un hiperplano

One-Class SVM

- Versión modificada para problemas OCC
- Separación de única clase del origen
- Transformación a otros espacios
  - *Radial Basis Function* (RBF) kernel

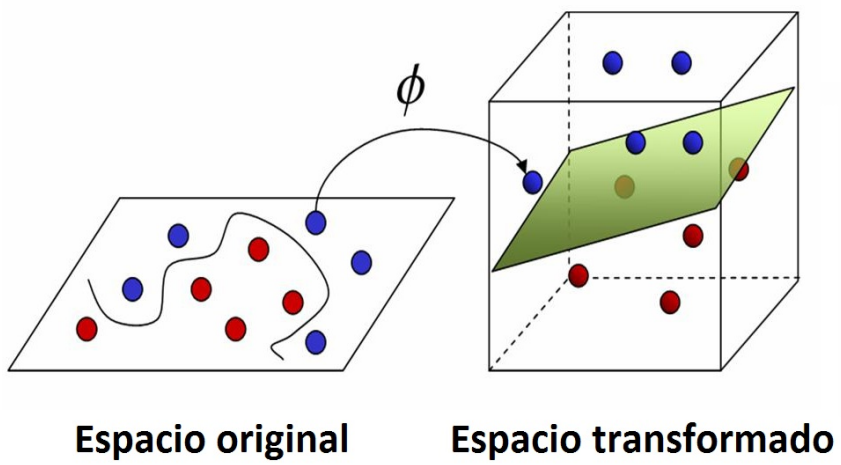

3. Paso de entrenamiento de clasificadores

3. Paso de entrenamiento de clasificadores

- Un One-Class SVM por cada grupo G_i
- Entrenamiento realizado con los vectores de *features* construidos
- Almacenamiento persistente del clasificador entrenado

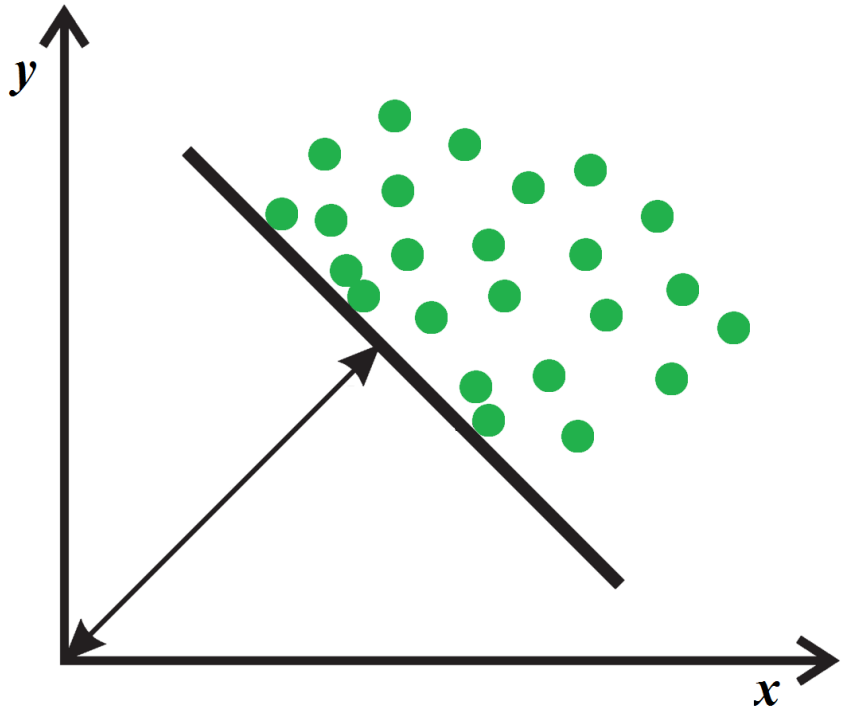

Fase de detección

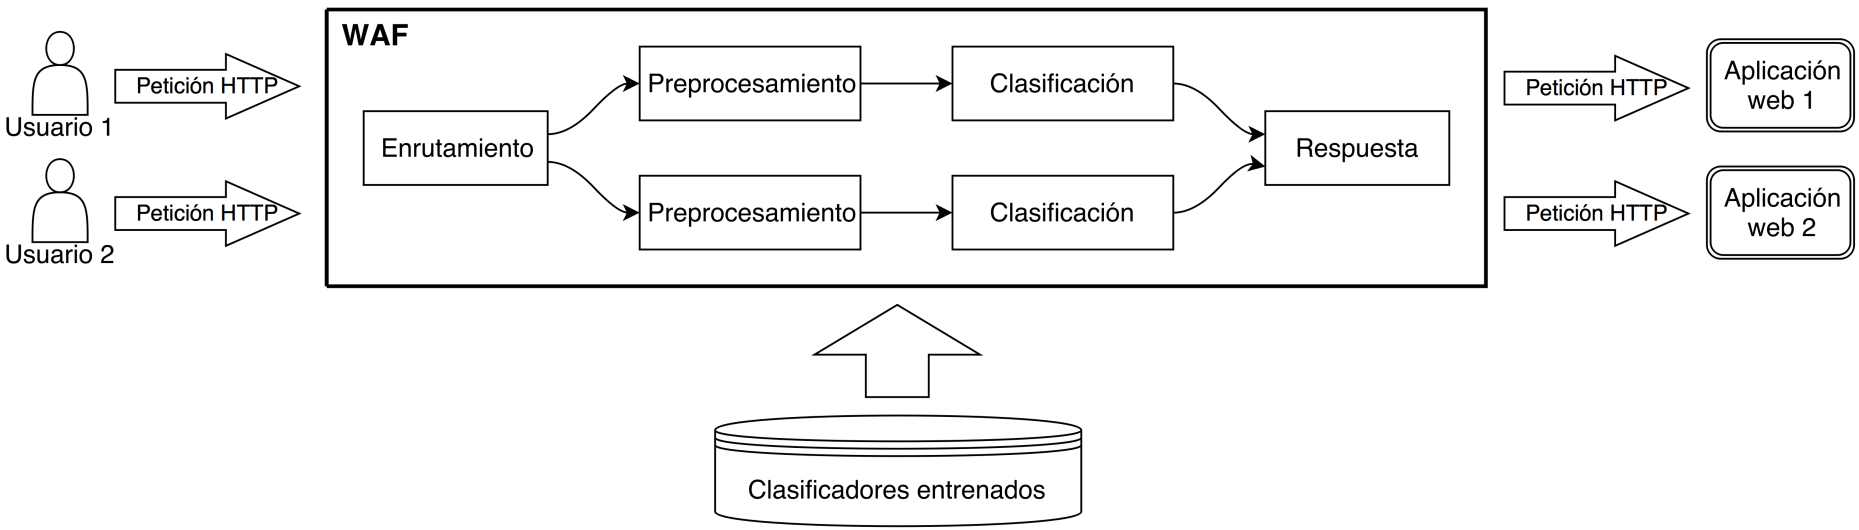

1. Paso de enrutamiento

1. Paso de enrutamiento

- Identificación del grupo G_i de las nuevas peticiones según su método HTTP y URL
- Delegación al proceso de extracción de *features* del grupo y al clasificador correspondiente

2. Paso de preprocesamiento

2. Paso de preprocesamiento

- Construcción de vectores de *features* para nuevas peticiones
- Uso de las listas de parámetros Q_i y B_i para la extracción de valores
- Nuevos parámetros no contenidos en estas listas no agregan *features* al vector
- Vectores construidos con misma dimensión n_i del grupo

3. Paso de clasificación

3. Paso de clasificación

- Uso del hiperplano obtenido para el grupo G_i
- Análisis de la posición de nuevas peticiones:
  - Lado opuesto al origen:
    - Petición normal
  - Mismo lado que el origen:
    - Petición anómala o ataque

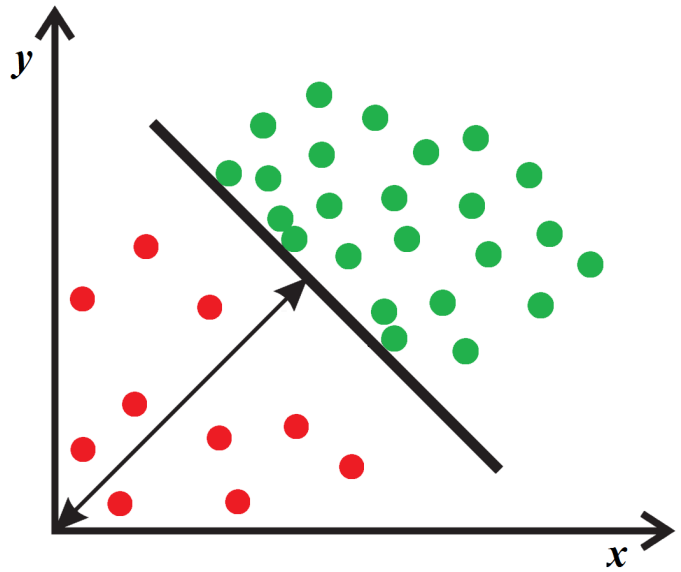

4. Paso de respuesta

4. Paso de respuesta

- Distintas acciones como respuesta al resultado de clasificación
- Peticiones normales:
  - Reenvío a las aplicaciones web destino
- Peticiones anómalas:
  - Registro en un *log*
  - Opcionalmente: bloqueo de la petición

Contenido

Conjuntos de datos utilizados

- Conjuntos utilizados:
  - CSIC 2010[8]
  - CSIC TORPEDA 2012[9]
- Peticiones HTTP simuladas a una aplicación de comercio electrónico
- Distintos tipos de ataques
  - Inyección SQL, *buffer overflow*, *cross-site scripting* (XSS), entre otros
- Datos utilizados:
  - 18 grupos de peticiones según método HTTP y URL
  - 40 130 peticiones normales y 42 444 anomalías

[8] http://www.isi.csic.es/dataset/
[9] http://www.tic.itefi.csic.es/torpeda

Pruebas de eficacia de detección

		Clasificación real	
		N Negatives (peticiones normales)	P Positives (peticiones anómalas)
Detección obtenida	Negatives (peticiones detectadas como normales)	TN True Negatives (peticiones normales detectadas correctamente como normales)	FN False Negatives (peticiones anómalas detectadas incorrectamente como normales)
	Positives (peticiones detectadas como anómalas)	FP False Positives (peticiones normales detectadas incorrectamente como anómalas)	TP True Positives (peticiones anómalas detectadas correctamente como anómalas)

$$\text{TPR} = \frac{\text{TP}}{\text{P}} \quad , \quad \text{FPR} = \frac{\text{FP}}{\text{N}} \quad , \quad \text{F}_1\text{-}score = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}}$$

- F_1-*score* es más robusto frente a datos no balanceados

Pruebas de eficacia de detección

- Mejoras obtenidas por el análisis de valores de parámetros
  - Promedio de los 18 grupos
  - $\approx$ 2 000 peticiones normales en cada grupo
  - $\approx$ 1 300 peticiones anómalas en cada grupo
  - Usando 1 500 peticiones para entrenamiento
    - $\approx 75\%$ de los datos normales
  - 3 iteraciones con distintos conjuntos de entrenamiento

	TPR	FPR	F_1-*score*
Solo petición completa	0.77 ± 0.28	0.11 ± 0.22	0.79 ± 0.23
Con análisis de parámetros	0.93 ± 0.11	0.03 ± 0.03	0.95 ± 0.08

Pruebas de tiempo de respuesta

- Medición del impacto de OCS-WAF sobre las aplicaciones protegidas
  - Promedio de los 18 grupos
  - 100 peticiones de cada grupo

	Tiempo de respuesta promedio (en milisegundos)
Directo a la aplicación web	4,0 $\pm$ 0,6
A través de OCS-WAF	8,7 $\pm$ 1,3

Pruebas de tiempo de entrenamiento

- Medición de relación entre tiempo de entrenamiento y cantidad de peticiones utilizadas
  - Duración máxima de los 18 grupos

Cantidad de peticiones	Tiempo por petición (en milisegundos)	Duración total
10	2,0	< 1 segundos
100	1,7	< 1 segundos
1 000	1,7	< 2 segundos
10 000	1,8	< 20 segundos
100 000	7,0	< 12 minutos

Trabajos relacionados de otros autores

- Utilización del mismo conjunto de datos CSIC 2010

Sistema de detección	TPR	FPR	F_1-*score*
OCS-WAF	0,93	0,03	0,95
ModSecurity[10] [11]	0,56	0,00	0,71
HTTP-WS-AD[12]	0,99	0,02	0,99
Árboles de decisión - Torrano-Giménez[13]	0,95	0,05	-
OC-WAD[14]	0,96	0,03	-

[10] https://www.modsecurity.org/
[11] Giménez (2015) HTTP-WS-AD: Detector de anomalías orientada a aplicaciones web y web services.
[12] Giménez (2015) HTTP-WS-AD: Detector de anomalías orientada a aplicaciones web y web services.
[13] Torrano-Giménez (2015) Study of stochastic and machine learning techniques for anomaly-based detection.
[14] Parhizkar y Abadi (2015) OC-WAD: A one-class classifier ensemble approach for anomaly detection.

Contenido

OCS-WAF

- Implementación de un WAF para protección de múltiples aplicaciones web
- Detección de anomalías en mensajes HTTP mediante clasificadores One-Class SVM

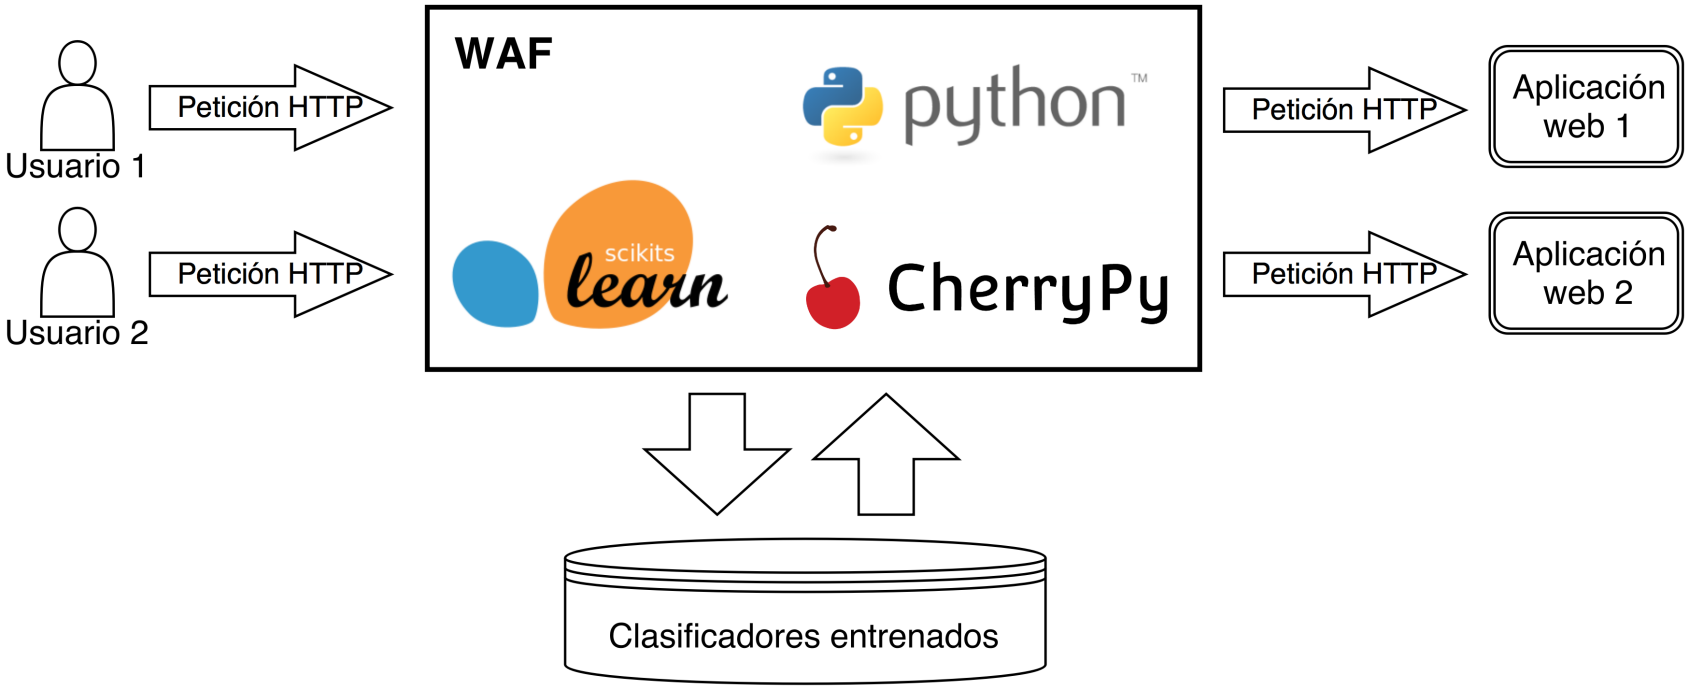

Objetivos específicos

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.
   - Diseño de nuevos procesos de extracción de *features* para mensajes HTTP

Objetivos específicos

1. Diseñar procesos de extracción de características (*features*) específicamente para mensajes HTTP, basado en aportes de otros investigadores de la literatura.
   - Diseño de nuevos procesos de extracción de *features* para mensajes HTTP
2. Implementar un WAF basado en anomalías, utilizando los procesos de extracción de *features* diseñados junto con clasificadores One-Class SVM.
   - Implementación de OCS-WAF

Objetivos específicos

3. Evaluar la eficacia del WAF implementado en cuanto a la detección de mensajes HTTP anómalos.
   - Pruebas de eficacia de detección con un TPR de 0,93, FPR de 0,03 y F_1-*score* de 0,95

Objetivos específicos

3. Evaluar la eficacia del WAF implementado en cuanto a la detección de mensajes HTTP anómalos.
   - Pruebas de eficacia de detección con un TPR de 0,93, FPR de 0,03 y F_1-*score* de 0,95
4. Analizar la viabilidad de utilizar el WAF implementado para detección de ataques en tiempo real.
   - Realización de pruebas de impacto de OCS-WAF sobre el tiempo de respuesta de las aplicaciones protegidas

Objetivo general

Objetivo general

- Detectar mensajes HTTP anómalos entre las aplicaciones web y sus usuarios con el fin de mitigar los riesgos de ataques contra dichas aplicaciones, utilizando un WAF basado en clasificadores One-Class SVM.
  - Detección de mensajes HTTP anómalos con OCS-WAF

Ideas para trabajos futuros

Ideas para trabajos futuros

- Realizar pruebas con otros conjuntos de datos.

Ideas para trabajos futuros

- Realizar pruebas con otros conjuntos de datos.
- Explorar otras características de los mensajes HTTP.

Ideas para trabajos futuros

- Realizar pruebas con otros conjuntos de datos.
- Explorar otras características de los mensajes HTTP.
- Extender para incluir cuerpos de otros formatos, por ejemplo datos binario, JSON, XML, entre otros.

Ideas para trabajos futuros

- Realizar pruebas con otros conjuntos de datos.
- Explorar otras características de los mensajes HTTP.
- Extender para incluir cuerpos de otros formatos, por ejemplo datos binario, JSON, XML, entre otros.
- Extender para incluir mensajes HTTP/2.

Ideas para trabajos futuros

- Realizar pruebas con otros conjuntos de datos.
- Explorar otras características de los mensajes HTTP.
- Extender para incluir cuerpos de otros formatos, por ejemplo datos binario, JSON, XML, entre otros.
- Extender para incluir mensajes HTTP/2.
- Explorar la posibilidad de paralelizar el proceso de entrenamiento en OCS-WAF.

Publicación de nuestro trabajo

- **Título:** Anomaly-based Web Application Firewall using HTTP-specific features and One-Class SVM

WRSeg 2017

- Workshop Regional de Segurança da Informação e Sistemas Computacionais
- Santa María, Brasil
- 25 de Setiembre 2017

Revista REABTIC

- Revista Eletrônica Argentina-Brasil de Tecnologias da Informação e da Comunicação
- Enviado para revisión

Gracias por su atención!

https://github.com/nico-ralf-ii-fpuna/tfg

Anexo: One-Class SVM

- Hiperplano del clasificador para el grupo G_i

$$\vec{w_i} \cdot \phi(\vec{x}) \; - \; \rho_i \; = \; \sum_{j=1}^{|G_i|} \left(a_{ij} \, K_i(\vec{f_{ij}}, \vec{x}) \right) \; - \; \rho_i \; = \; 0 \qquad (1)$$

- Kernel Radial Basis Function (RBF)

$$K(\vec{x_1}, \vec{x_2}) \; = \; \phi(\vec{x_1}) \cdot \phi(\vec{x_2}) \; = \; \exp(-\gamma \|\vec{x_1} - \vec{x_2}\|^2) \qquad (2)$$

Anexo: One-Class SVM

- Entrenamiento: problema de minimización para el grupo G_i

$$\min_{\vec{w}_i\ ,\ \rho_i\ ,\ \xi_i} \ \frac{1}{2}\|\vec{w}_i\|^2 \ - \ \rho_i \ + \ \frac{1}{\nu_i|G_i|}\sum_{j=1}^{|G_i|}\xi_{ij} \tag{3}$$

$$\vec{w}_i \cdot \phi(\vec{f}_{ij}) \geqslant \rho_i - \xi_{ij}\ , \quad \xi_{ij} \geqslant 0\ , \quad \forall j = 1, 2, \ldots, |G_i| \tag{4}$$

- Entrenamiento: formulación dual de la optimización

$$\min_{a_i} \ \frac{1}{2}\ a_i\ S_i\ a_i^T \tag{5}$$

$$\sum_{j=1}^{|G_i|} a_{ij} \ = \ 1\ , \quad 0 \leqslant a_{ij} \leqslant \frac{1}{\nu_i|G_i|}\ \forall j = 1, 2, \ldots, |G_i| \tag{6}$$

Anexo: One-Class SVM

- Detección: función de decisión del grupo G_i

$$g_i(\vec{x}) = \begin{cases} \vec{w_i} \cdot \phi(\vec{x}) - \rho_i \geqslant 0 & +1 \\ \text{caso contrario} & -1 \end{cases} \tag{7}$$

$$g_i(\vec{x}) = \begin{cases} \sum_{j=1}^{|G_i|} \left(a_{ij} K_i(\vec{f_{ij}}, \vec{x}) \right) - \rho_i \geqslant 0 & +1 \\ \text{caso contrario} & -1 \end{cases} \tag{8}$$

Anexo: Datos utilizados para las pruebas

- Información sobre los 18 grupos de peticiones

ID	Conjunto de datos CSIC	Método HTTP y URL		Cant. parám.	Peticiones normales	Peticiones anómalas
c00	2010	GET	/tienda1/miembros/editar.jsp	13	2 000	1 362
c01	2010	POST	/tienda1/miembros/editar.jsp	13	2 000	1 362
c02	2010	GET	/tienda1/publico/anadir.jsp	5	2 000	1 380
c03	2010	POST	/tienda1/publico/anadir.jsp	5	2 000	1 380
c04	2010	GET	/tienda1/publico/autenticar.jsp	5	2 000	1 361
c05	2010	POST	/tienda1/publico/autenticar.jsp	5	2 000	1 361
c06	2010	GET	/tienda1/publico/caracteristicas.jsp	1	2 000	954
c07	2010	POST	/tienda1/publico/caracteristicas.jsp	1	2 000	954
c08	2010	GET	/tienda1/publico/entrar.jsp	1	2 000	897
c09	2010	POST	/tienda1/publico/entrar.jsp	1	2 000	897
c10	2010	GET	/tienda1/publico/pagar.jsp	3	2 000	1 343
c11	2010	POST	/tienda1/publico/pagar.jsp	3	2 000	1 343
c12	2010	GET	/tienda1/publico/registro.jsp	13	2 000	1 364
c13	2010	POST	/tienda1/publico/registro.jsp	13	2 000	1 364
c14	2010	GET	/tienda1/publico/vaciar.jsp	1	2 000	919
c15	2010	POST	/tienda1/publico/vaciar.jsp	1	2 000	919
t00	2012	POST	/tienda1/miembros/editar.jsp	12	5 608	10 121
t01	2012	POST	/tienda1/publico/registro.jsp	12	2 522	13 163
	Total				40 130	42 444

Anexo: Resultados de detección

- Resultados de los 18 grupos de peticiones

Grupo	TPR	FPR	F_1-*score*
c00	0,71 ± 0,01	0,05 ± 0,00	0,80 ± 0,00
c01	0,72 ± 0,01	0,05 ± 0,01	0,80 ± 0,00
c02	1,00 ± 0,00	0,03 ± 0,01	0,98 ± 0,01
c03	1,00 ± 0,00	0,03 ± 0,00	0,98 ± 0,00
c04	0,91 ± 0,01	0,01 ± 0,00	0,95 ± 0,01
c05	0,92 ± 0,01	0,01 ± 0,00	0,95 ± 0,00
c06	0,99 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c07	0,99 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c08	1,00 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c09	1,00 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c10	1,00 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c11	1,00 ± 0,00	0,01 ± 0,00	0,99 ± 0,00
c12	0,74 ± 0,00	0,05 ± 0,01	0,81 ± 0,01
c13	0,74 ± 0,00	0,05 ± 0,01	0,81 ± 0,01
c14	1,00 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
c15	1,00 ± 0,00	0,00 ± 0,00	1,00 ± 0,00
t00	0,99 ± 0,01	0,06 ± 0,04	0,98 ± 0,00
t01	1,00 ± 0,00	0,09 ± 0,06	0,99 ± 0,01
	0,93 ± 0,11	0,03 ± 0,03	0,95 ± 0,08

Anexo: Resultados de detección

- Resultados con anomalías entre los datos de entrenamiento

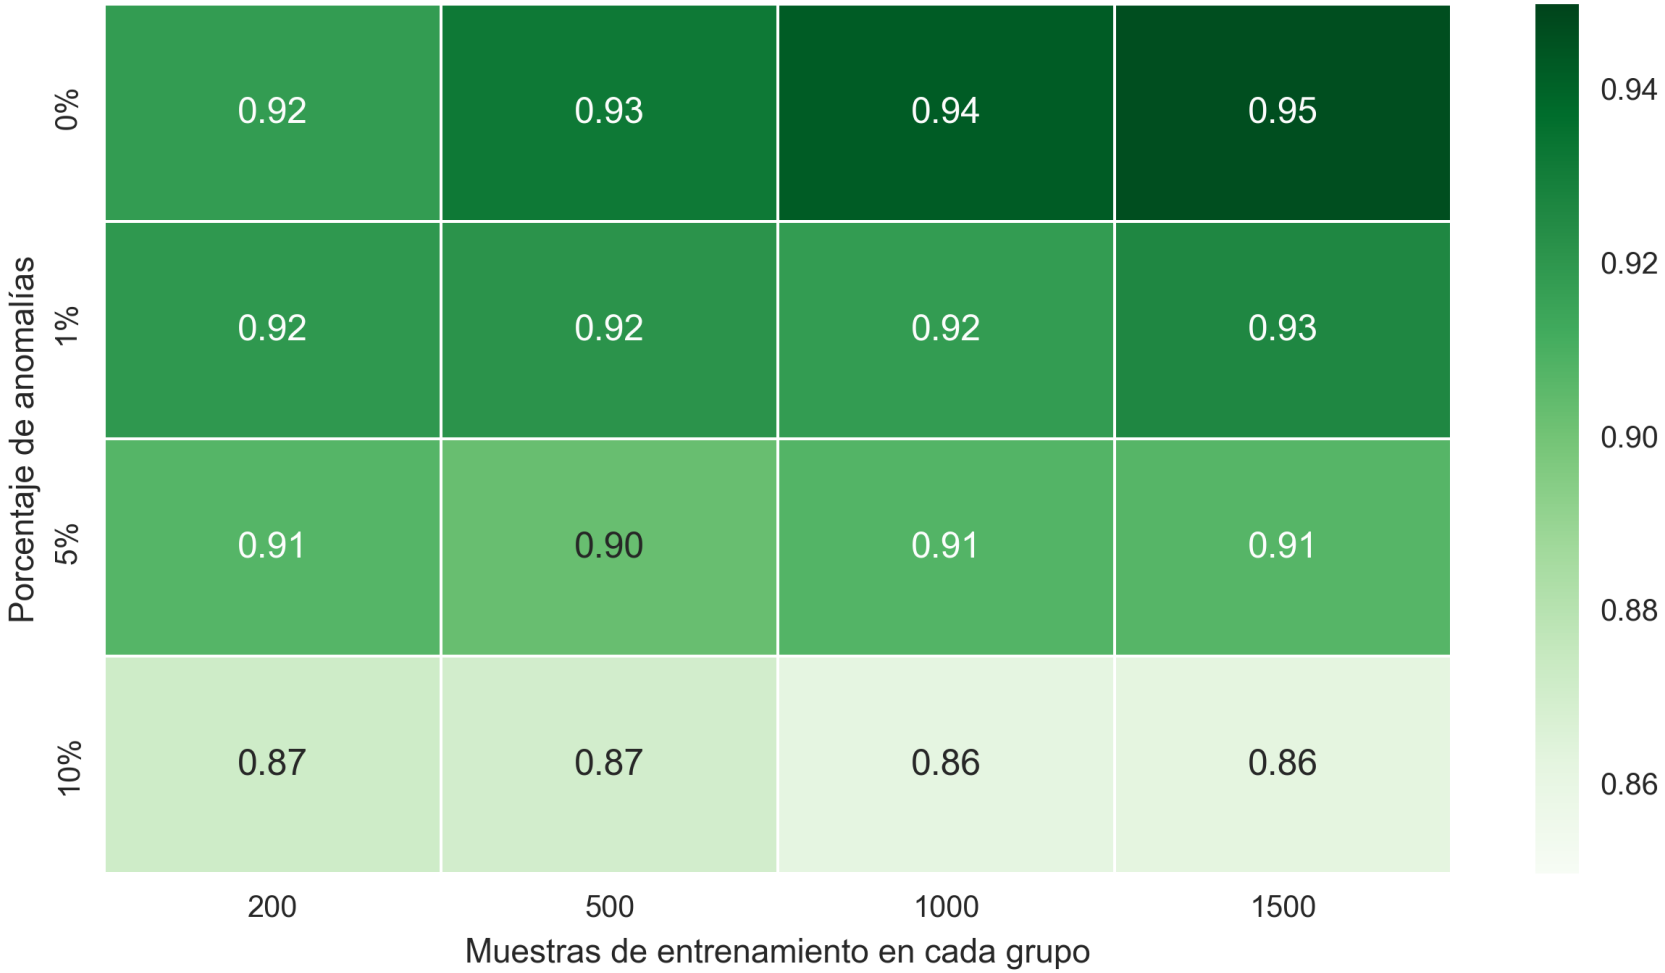

https://github.com/nico-ralf-ii-fpuna/tfg